



NLP para Notícias de Jogos

Stopwords · TF-IDF · Classificação com ML

Dados oriundos do site eurogamer.pt

Pipeline: do Dado Bruto ao Modelo



Dados

Pré-processo

TF-IDF

ML

Dados & Problema

1.249

Notícias

Artigos sobre jogos coletados e rotulados

9.183

Features TF-IDF

Dimensões originais da matriz esparsa

1.018

Amostras com rótulo

Instâncias válidas para treino e avaliação

62%

Multiplataforma

Distribuição das classes no dataset

 **Problema:** Dado apenas o **título** de uma notícia, prever se o jogo é **Multiplataforma** ou **Exclusivo**. Termos como "PC", "Xbox" e "PS5" foram bloqueados para evitar leakage.

Pré-processamento



Limpeza

Lower-case e remoção de pontuação

Stopwords

NLTK português + inglês (~350 palavras)

Anti-leakage

Bloqueio de nomes de plataforma

TF-IDF Implementado do Zero

TF — Frequência do Termo

$$\text{TF}(t, d) = \text{freq}(t, d) / |d|$$

IDF — Importância Inversa

$$\text{IDF}(t) = \log(N / (\text{df}(t)+1)) + 1$$

Score Final

$$\text{TF} \times \text{IDF} \rightarrow \text{normalização L2}$$

1.018


Documentos

2.344

Termos no Vocabulário

1018×2344

Dimensão da Matriz



RESULTADOS


Comparação de Modelos



Naive Bayes — Vencedor 🏆

O Naive Bayes superou os demais modelos em todas as métricas, com **AUC 0.857** e **Accuracy 77.9%**.

Comparação de Modelos



Resultados Completos

Modelo	AUC	F1 Macro	Acc.
Logístico	0.959	0.890	89,7%
Naive Bayes	0.944	0.876	87,2%
Random Forest	0.766	0.721	74,3%

📌 AUC original: **0,857** → após melhorias: **0,959** (+10 pontos)

O que Impulsionou o Ganho de +10 Pontos de AUC?



Tags sem Leakage

Maior ganho isolado — gênero e tema correlacionados com plataforma



Stemming RSLP

"lançamento", "lançado" e "lança" → mesmo token



Bigramas

"game pass" e "exclusivo nintendo" como features únicas



Stopwords de Domínio

Removeu ruído: "jogo", "trailer", "novo"



Grid Search no Alpha

Melhor valor: 2,0 (vs 0,5 original)



Conclusões

01

TF-IDF do zero é suficiente

Captura sinal em títulos curtos para classificação binária.

02

Features valem +10 pontos de AUC

Tags, stemming e bigramas

03

Bloqueio de leakage é essencial

Termos de plataforma no título resolveriam o problema trivialmente.

04

Próximo passo: BERTimbau

Embeddings contextuais para capturar semântica além do TF-IDF.