

</> NLP


Notícias de Jogos

STOPWORDS

TF-IDF

CLASSIFICAÇÃO ML

Dados providenciados do site eurogamer.pt



Made with GAMMA

Pipeline do Projeto

Baseado em quatro etapas



01 · Dados

1.249 notícias sobre jogos



02 · Pré-processo

Limpeza e remoção de stopwords



03 · TF-IDF

Implementado do zero



04 · ML

3 modelos comparados

DATASET

Dados & Problema

1.249

Notícias

Artigos sobre jogos coletados

9.183

Features

Termos TF-IDF originais

1.018

Amostras

Instâncias rotuladas

62%

Multi / 38% Excl.

Distribuição de classes

Problema

Dado apenas o **TÍTULO** de uma notícia de jogos, prever se o jogo é **Multiplataforma** ou **Exclusivo**.

Anti-leakage

Termos de plataforma (PC, Xbox, PS5...) foram **bloqueados das features** para evitar resolução trivial do problema.

Pré-processamento



Limpeza

Lower-case, remoção de pontuação
e caracteres especiais



Stopwords

NLTK português + inglês
combinados (~350 palavras)



Anti-leakage

Bloqueio de nomes de plataformas
(PC, Xbox, PS5...)

ANTES

*"Pokémon FireRed & LeafGreen inclui conteúdo ausente da
versão original"*

DEPOIS

`['pokémon', 'firered', 'leafgreen', 'inclui', 'conteúdo',
'ausente', 'versão', 'original']`

TF-IDF implementado do zero

TF — Frequência no Documento

$$TF(t,d) = \text{freq}(t, d) / |d|$$

IDF — Frequência Inversa

$$IDF(t) = \log(N / (df(t)+1)) + 1$$

Score Final

$TF \times IDF \rightarrow$ normalização L2

Saída da Matriz

1.018

Documentos

2.344

Termos no vocabulário

1018×2344


Dimensão da matriz

L2

Normalização por linha

RESULTADOS

Comparação de Modelos



Naive Bayes — Vencedor 🏆

O Naive Bayes superou os demais modelos em todas as métricas, com **AUC 0.857** e **Accuracy 77.9%**.

AUC CV 5-fold

0.822 — sem overfitting relevante. Treino e generalização alinhados.

Por que Naive Bayes ganhou?

1

Features esparsas

TF-IDF de títulos curtos gera matrizes esparsas. NB lida melhor com sparsity do que Random Forest.

2

Independência condicional

Em textos curtos, a suposição de independência é menos violada — tornando-se vantagem, não limitação.

3

Menos parâmetros

Com ~1k amostras, modelos simples generalizam melhor. RF com 200 árvores tende a overfittar.

Conclusões

1

TF-IDF do zero funciona

Captura sinal suficiente em títulos curtos para classificação binária eficaz.

2

AUC ~0.86 sem tunagem

Naive Bayes entregou bom desempenho sem ajuste de hiperparâmetros.

3

Anti-leakage é essencial

Termos de plataforma no título resolveriam o problema trivialmente.

4

Simples > Complexo

Modelos simples batem modelos complexos quando dados são escassos e features esparsas.